

Automatic Analysis of EMG signals

Cioponea Florentina-Teodora
Nicolae Mara-Raluca
Sanda Andreea

Introducere

Proiectul de față are ca obiectiv analiza și cuantificarea activității musculare prin procesarea semnalelor electromiografice de suprafață (sEMG) și este structurat pe două direcții principale: dezvoltarea unui sistem automat de clasificare a mișcărilor și evaluarea asimetriei musculare.

Prima componentă, Automatic Movement Classification System, vizează implementarea unui sistem capabil să recunoască automat tipul de mișcare efectuat, cu accent pe diferențierea între mai multe exerciții ale brațului. În acest scop, a fost antrenată o rețea neuronală de tip Fully Connected Neural Network (FCNN) utilizând un set de date colectat de la 100 de subiecți, în timpul executării a trei tipuri distincte de flexii. Performanța modelului a fost evaluată atât în etapa de antrenare, cât și în cea de validare, folosind metrii de acuratețe ponderată și neponderată.

Cea de-a doua componentă, Assessing Muscle Asymmetry, constă într-un studiu experimental dedicat analizei diferențelor de activare între mușchi simetrici sau grupuri musculare înregistrate simultan, precum flexorii și extensorii. Pentru cuantificarea gradului de asimetrie musculară, au fost extrași și analizați parametri specifici semnalelor sEMG, precum RMS (Root Mean Square), Skewness, precum și coeficientul de asimetrie KAs.

Întregul cadru computațional, de la preprocesare și extragerea trăsăturilor în domeniul timpului până la simulările finale, a fost dezvoltat în mediul de lucru Spyder.

Sistemul de clasificare a mișcării

Pentru a putea rezolva problema de clasificare, am ales o rețea neurală complet conectată (FCNN) cu trei straturi ascunse, de dimensiuni 64, 32 și 16 neuroni, utilizând funcții de activare ReLU și un strat de ieșire cu funcție de activare softmax. Optimizatorul folosit a fost *adam*, iar antrenarea limitată în timp (Early Stopping) a fost implementată, folosind patiencecu valoarea 25 pentru a limita epociile consecutive în care semnalul de alarmă nu este declanșat deși mărimea nu evoluează cum ar trebui. ModelCheckpoint monitorizează funcția cost pe validare și salvează modelul într-un fișier keras la fiecare epocă la care aceasta a ajuns la o valoare mai mică.

Preprocesarea semnalelor sEMG a constat în uniformizarea datelor și eliminarea componentei DC prin scăderea mediei fiecărui canal. Această etapă reduce deplasările de bază ale semnalului cauzate de contactul electrozilor și a fost menținută la un nivel minim, fără aplicarea unei filtrări suplimentare, pentru a evita distorsionarea caracteristicilor temporale.

Semnalele sEMG au fost segmentate în ferestre suprapuse de 512 eșantioane, cu un pas de 256 eșantioane. Pentru normalizare am folosit Z-score, fiind o metodă simplu de implementat, ce face calculul mediei pentru fiecare trăsătură.

Extragerea trăsăturilor a fost realizată în domeniul timpului, prin calcularea unui set de caracteristici pe fiecare fereastră și pe fiecare canal. Au fost utilizate Mean Absolute Value (MAV) și Root Mean Square (RMS) pentru a cuantifica nivelul de activare musculară și energia semnalului, Waveform Length (WL) pentru a surprinde complexitatea și dinamica semnalului, precum și Zero Crossing Rate (ZCR) și Slope Sign Changes (SSC). ZCR și SSC au fost calculate cu prag adaptiv, definit ca 1% din deviația standard a semnalului pe fiecare fereastră, reducând sensibilitatea la fluctuații minore și asigurând stabilitatea trăsăturilor între ferestre și subiecți. Skewness a fost inclusă pentru a caracteriza asimetria distribuției amplitudinii semnalului într-o fereastră, completând măsurile bazate pe energie. Caracteristicile au fost extrase independent pentru fiecare canal și concatenate într-un singur vector de intrare, permitând păstrarea informației spațiale între mușchii implicați și oferind o reprezentare compactă și cuprinzătoare.

Am ales să măsurăm performanța prin măsurarea acurateței ponderate și neponderate medie de-a lungul claselor. Clasele s-au dovedit a fi echilibrate, UA fiind egală cu WA și la antrenare și la validare. Matricea de confuzie a fost utilizată pentru a analiza în detaliu performanța sistemului, oferind informații despre clasificările corecte și erorile dintre clase.

Evaluarea asimetriei musculare

Pentru studiul dedicat asimetriei musculare, am început prin identificarea și încărcarea înregistrărilor sEMG din primul set de date oferit. Primul pas în procesarea datelor a constat în eliminarea componentei continue pentru a centra semnalul în jurul valorii zero, urmată de segmentarea acestuia în ferestre de **512 eșantioane** cu o suprapunere de **50%**. Această abordare ne-a permis să extragem cu precizie parametru RMS pentru a măsura energia musculară depusă și Skewness pentru a analiza asimetria distribuției amplitudinii la nivelul fiecărui segment temporal. În continuare am segmentat cele 8 canale de înregistrare în două grupuri, **GROUPA (canalele 0-3)** și **GROUPB (canalele 4-7)**, reprezentând musculatura flexoare, respectiv cea extensoare, pentru a putea cuantifica diferențele de activare simultană.

Evaluarea asimetriei a fost realizată prin aplicarea formulei pentru coeficientul KAs, unde am realizat o normalizare prin raportarea diferenței absolute la valoarea maximă a grupului dominant.

În final, codul asimetriei unește toate aceste rezultate la nivel de subiect și de clasă de mișcare, generând automat rapoarte statistice detaliate (medie, deviație standard, valori extreme) exportate în fișiere CSV, care facilitează încadrarea subiecților în clase de asimetrie, de la starea de sănătate până la asimetrie ridicată.